

CS308 Computer Vision 复习考点、公式与模拟卷

本文根据当前目录下 14 份课件整理：Lecture 1-13 与 Lecture 15。重点放在考试常考概念、英文术语、计算公式、做题步骤，以及一套模拟试卷。

一、总览：这门课到底考什么

CS308 的主线是：图像如何形成，如何被处理，如何被表示，如何被机器学习模型理解，最后如何进入检测、分割、跟踪和视觉语言任务。

可以按 5 条线复习：

1. **图像形成 Image Formation**：3D 世界如何通过相机投影到 2D 图像。
2. **低层视觉 Low-Level Vision**：像素、滤波、频域、金字塔、角点、特征描述子。
3. **模型拟合与机器学习 Fitting and ML**：最小二乘、RANSAC、Hough、PCA、SVM、神经网络。
4. **视觉识别 Recognition**：目标检测、语义分割、实例分割、目标跟踪。
5. **视觉语言 Vision-Language**：图像描述、跨模态检索、VQA、RNN/LSTM/Transformer。

高频考点通常包括：

- 卷积/相关计算、padding、stride、CNN 输出尺寸。
- 相机投影矩阵、针孔相机、消失点。
- Harris 角点、SIFT、DoG、特征匹配。
- 最小二乘、RANSAC 迭代次数、Hough 变换。
- PCA、SVM、kernel trick、softmax/cross entropy。
- IoU、AP、mAP、NMS、Viola-Jones、R-CNN/Fast/Faster R-CNN、YOLO。
- FCN、反卷积/转置卷积、dilated convolution、mIoU、RoI Align。
- Kalman filter、Siamese tracker、Deep SORT。
- Self-attention、Transformer、Encoder-Decoder。

二、关键概念：中英文解释

Lecture 1：计算机视觉导论

Computer Vision 计算机视觉

- 中文：让机器从图像、视频等视觉数据中“看见、理解、预测”的技术。
- English: The science and technology of machines that capture, understand, and predict visual information.
- 考点：计算机视觉不是只“看图”，还包括分类、检测、分割、跟踪、生成、视觉语言等任务。

Image Classification 图像分类

- 中文：判断整张图属于哪个类别。
- English: Assigning a category label to an entire image.
- 例子：输入一张图片，输出“汽车”“道路”“建筑”等类别。

Object Detection 目标检测

- 中文：找出图像中有哪些目标，并给每个目标画边界框。
- English: Locating and classifying objects in an image, usually with bounding boxes.
- 输出：类别 class + bounding box + confidence score。

Semantic Segmentation 语义分割

- 中文：给每个像素分类。属于同一类的不同个体不区分。
- English: Assigning a semantic class label to each pixel.
- 例子：所有道路像素标成 road，所有人像素标成 person。

Instance Segmentation 实例分割

- 中文：不仅给像素分类，还区分同类中的不同实例。
- English: Pixel-level segmentation that distinguishes different object instances.

Object Tracking 目标跟踪

- 中文：在视频中持续估计目标的位置。
- English: Estimating the state or location of a target object over time in video.

Visual Grounding 视觉定位/视觉指代

- 中文：给定文字描述，在图像中找到对应区域。
- English: Localizing image regions referred to by a language expression.

Image Captioning 图像描述

- 中文：让模型根据图像生成自然语言句子。
- English: Generating a natural language description for an image.

Visual Question Answering, VQA 视觉问答

- 中文：给模型一张图和一个问题，让它回答。
- English: Answering natural language questions about visual content.

Lecture 2：图像形成

Image Formation 图像形成

- 中文：3D 世界经过相机、光照、传感器采样，变成 2D 数字图像矩阵的过程。
- English: The process of mapping a 3D scene through optics and sensing into a 2D digital image.

Pinhole Camera Model 针孔相机模型

- 中文：把相机看成一个小孔，3D 点通过小孔投影到成像平面。
- English: A camera model where scene points project through a pinhole onto an image plane.
- 核心：远的东西投影小，近的东西投影大。

Perspective Projection 透视投影

- 中文：3D 点除以深度 Z 后得到 2D 坐标。
- English: Projection where image coordinates are obtained by dividing by depth.
- 公式： $u = fX/Z + c_x$, $v = fY/Z + c_y$ 。

Orthographic Projection 正交投影

- 中文：忽略深度带来的大小变化，平行投影到图像平面。
- English: Projection that ignores depth-dependent scaling.

Homogeneous Coordinates 齐次坐标

- 中文：给坐标多加一个维度，使平移、投影等操作可以统一写成矩阵乘法。
- English: Coordinates with an extra scale dimension that allow projective transforms to be represented linearly.
- 2D 点 (x, y) 写成 $(x, y, 1)$ ，并且 $(x, y, 1)$ 与 (kx, ky, k) 表示同一点。

Intrinsic Matrix 相机内参矩阵

- 中文：描述相机自身参数，如焦距、主点、像素比例。
- English: A matrix describing camera-internal parameters such as focal lengths and principal point.

Extrinsic Parameters 外参

- 中文：描述世界坐标系到相机坐标系的旋转 R 和平移 t 。
- English: Rotation and translation mapping world coordinates into camera coordinates.

Camera Projection Matrix 相机投影矩阵

- 中文：把世界坐标中的 3D 点投影到图像坐标中的矩阵。
- English: A matrix mapping 3D world points to 2D image points.
- 公式： $\lambda \mathbf{x} = \mathbf{K} [\mathbf{R} \mid \mathbf{t}] \mathbf{X}$ 。

Vanishing Point 消失点

- 中文：现实中平行的线，在透视图像中可能相交于一个点。
- English: The image point where projections of parallel 3D lines meet.

Radial Distortion 径向畸变

- 中文：镜头使图像向外鼓或向内缩，常见为 barrel distortion 或 pincushion distortion。
- English: Lens distortion where points move radially from or toward the image center.

Sampling and Quantization 采样与量化

- 中文：采样把连续图像变成离散像素；量化把连续亮度变成有限灰度级。
- English: Sampling discretizes space; quantization discretizes intensity.

Color Filter Array, CFA 颜色滤波阵列

- 中文：传感器每个像素通常只测一种颜色，再通过插值恢复 RGB。
- English: A sensor pattern that samples different color channels at different pixel sites.

Lecture 3: 线性滤波与邻域操作

Point Operator 点运算

- 中文：输出像素只依赖输入图像同一位置的像素。

- English: An operator where each output pixel depends only on the corresponding input pixel.
- 例子：亮度调整、对比度调整、gamma correction、颜色空间变换。

Histogram Equalization 直方图均衡化

- 中文：用累积分布函数重新映射灰度，让图像对比度更均衡。
- English: Remapping intensities using the cumulative distribution so the output histogram is more uniform.

Linear Filtering 线性滤波

- 中文：用一个小矩阵 kernel 在图像上滑动，对邻域像素做加权求和。
- English: Sliding a kernel over an image and computing a weighted sum of neighboring pixels.

Correlation 相关

- 中文：核不翻转，直接与图像邻域做乘加。
- English: Weighted summation with the kernel used as-is.

Convolution 卷积

- 中文：先把核水平和垂直翻转 180°，再与图像邻域做乘加。
- English: Weighted summation after flipping the kernel by 180 degrees.
- 注意：很多深度学习框架实现的“convolution”实际更接近 correlation。

Padding 边界填充

- 中文：在图像边缘补像素，使滤波后尺寸可控。
- English: Adding pixels around image borders to control output size.
- 常见：zero padding、replicate padding、reflect padding。

Separable Filter 可分离滤波器

- 中文：二维核可写成两个一维核的外积，计算更快。
- English: A 2D filter that can be decomposed into two 1D filters.
- 复杂度： $K \times K$ 卷积从 K^2 次乘加降到 $2K$ 次乘加。

Gaussian Filter 高斯滤波

- 中文：按距离远近给邻域加权，越近权重越大，用于平滑降噪。
- English: A smoothing filter with weights following a Gaussian distribution.

Median Filter 中值滤波

- 中文：取邻域中位数，常用于去除椒盐噪声。
- English: A nonlinear filter that replaces a pixel by the median of its neighborhood.

Bilateral Filter 双边滤波

- 中文：同时考虑空间距离和像素值差异，既平滑又保边。
- English: An edge-preserving filter using both spatial closeness and intensity similarity.

Integral Image 积分图

- 中文：每个位置存左上区域像素和，用于快速计算矩形区域求和。
- English: A summed-area table enabling constant-time rectangle sum computation.

Morphology 形态学

- 中文：对二值图像进行膨胀、腐蚀、开运算、闭运算。
- English: Binary image operations such as dilation, erosion, opening, and closing.

Lecture 4: 频域与金字塔

Frequency Domain 频域

- 中文：把图像看成不同频率的波叠加；低频是平滑区域，高频是边缘和细节。
- English: A representation where an image is decomposed into components of different frequencies.

Fourier Transform 傅里叶变换

- 中文：把空间图像转换成频率成分。
- English: Transforming a signal from spatial/time domain to frequency domain.

Magnitude and Phase 幅值与相位

- 中文：幅值表示某个频率有多少，相位包含空间位置信息。
- English: Magnitude shows frequency strength; phase carries spatial layout information.

Convolution Theorem 卷积定理

- 中文：空间域卷积等价于频域乘法。
- English: Convolution in the spatial domain corresponds to multiplication in the frequency domain.

Gaussian Pyramid 高斯金字塔

- 中文：不断平滑并下采样，得到多分辨率图像。
- English: A multi-resolution representation built by smoothing and downsampling.

Laplacian Pyramid 拉普拉斯金字塔

- 中文：保存相邻高斯层之间的差，即细节/高频信息。
- English: A pyramid storing band-pass residuals between adjacent Gaussian levels.

Interpolation 插值

- 中文：估计非整数坐标处的像素值。
- English: Estimating pixel values at non-integer coordinates.

Decimation 下采样

- 中文：降低分辨率，通常要先低通滤波避免 aliasing。
- English: Downsampling a signal, usually after low-pass filtering to avoid aliasing.

Forward Warping 正向变形

- 中文：把源图像像素推到目标位置，容易产生空洞。
- English: Mapping source pixels forward to target positions, often causing holes.

Inverse Warping 反向变形

- 中文：对目标图像每个像素反查源图像位置，更常用。
- English: For each target pixel, sample from the corresponding source location.

Lecture 5: 兴趣点、角点与 SIFT

Correspondence 对应关系

- 中文：在多张图中找到表示同一真实点/区域的特征。
- English: Matching points, patches, edges, or regions across images.

Interest Point 兴趣点

- 中文：图像中稳定、独特、容易重复检测的点。
- English: A distinctive and repeatable image point useful for matching.

Repeatability 可重复性

- 中文：图像变化后还能检测到同一个点。
- English: The ability to detect the same point under transformations.

Distinctiveness 可区分性

- 中文：描述子足够独特，不容易匹配错。
- English: The descriptor is discriminative enough to avoid ambiguous matches.

Harris Corner Detector Harris 角点检测

- 中文：如果窗口向任意方向小移动都会变化很大，该点是角点。
- English: A corner detector based on strong intensity changes in all local directions.

Second Moment Matrix / Structure Tensor 二阶矩阵/结构张量

- 中文：统计局部窗口内 x、y 方向梯度及其相关性。
- English: A matrix summarizing local gradient variation.

Scale Selection 尺度选择

- 中文：在不同模糊尺度下寻找最稳定的特征点。
- English: Selecting the scale where a feature response is most characteristic.

Laplacian of Gaussian, LoG 高斯拉普拉斯

- 中文：先高斯平滑，再用拉普拉斯检测 blob。
- English: Applying Laplacian after Gaussian smoothing to detect blob-like structures.

Difference of Gaussian, DoG 高斯差分

- 中文：两个不同尺度高斯模糊图像相减，近似 LoG。
- English: Difference between Gaussian-smoothed images at adjacent scales, approximating LoG.

SIFT 特征

- 中文：尺度、旋转相对稳定的局部特征检测与描述方法。
- English: Scale-Invariant Feature Transform, a local feature detector and descriptor.
- 典型描述子：4×4 cells，每个 cell 8 个方向 bins，总维度 128。

Nearest Neighbor Distance Ratio, NNDR 最近邻距离比

- 中文：用最近邻距离和次近邻距离的比值判断匹配是否可靠。
- English: A matching test comparing the nearest and second-nearest descriptor distances.

Lecture 6: 拟合、RANSAC 与 Hough

Model Fitting 模型拟合

- 中文：用一组观测点估计模型参数，例如线、圆、变换矩阵。
- English: Estimating model parameters from observed data.

Ordinary Least Squares, OLS 普通最小二乘

- 中文：最小化 y 方向残差平方和。
- English: Minimizing the squared vertical residuals.

Total Least Squares, TLS 总最小二乘

- 中文：最小化点到模型的正交距离平方和。
- English: Minimizing squared orthogonal distances to the model.

Robust Estimator 鲁棒估计

- 中文：降低离群点对拟合结果的影响。
- English: An estimator designed to reduce the influence of outliers.

RANSAC 随机采样一致性

- 中文：反复随机抽最小样本拟合模型，再统计支持它的内点。
- English: Repeatedly fitting models from random minimal samples and selecting the one with the largest consensus set.

Hough Transform 霍夫变换

- 中文：让图像空间的点在参数空间投票，峰值对应模型。
- English: A voting method where image features vote in parameter space.

Affine Transformation 仿射变换

- 中文：保留平行性，可表示平移、旋转、缩放、剪切。
- English: A transformation preserving parallel lines.

Homography 单应性

- 中文：描述平面到平面之间的投影变换。
- English: A projective transformation between two planes.

Lecture 7: 降维与流形学习

Dimensionality Reduction 降维

- 中文：把高维数据映射到低维，同时尽量保留重要结构。
- English: Mapping high-dimensional data to lower dimensions while preserving important structure.

Principal Component Analysis, PCA 主成分分析

- 中文：寻找方差最大的正交方向作为新坐标轴。
- English: Finding orthogonal directions of maximum variance.

Covariance Matrix 协方差矩阵

- 中文：描述不同维度一起变化的程度。
- English: A matrix describing how variables vary together.

Kernel PCA 核 PCA

- 中文：通过核函数隐式映射到高维空间后做 PCA。
- English: PCA performed implicitly in a high-dimensional feature space using kernels.

Manifold Learning 流形学习

- 中文：认为高维数据其实躺在低维弯曲表面上，目标是展开它。
- English: Learning low-dimensional structure embedded in high-dimensional data.

Locally Linear Embedding, LLE 局部线性嵌入

- 中文：保留每个点由邻居线性重构的关系。
- English: Preserving local reconstruction weights from neighbors.

Laplacian Eigenmaps, LE 拉普拉斯特征映射

- 中文：用图拉普拉斯保持相邻点在低维中仍然接近。
- English: Using graph Laplacian eigenvectors to preserve local neighborhood similarity.

Multidimensional Scaling, MDS 多维尺度分析

- 中文：在低维中尽量保持点对距离。
- English: Low-dimensional embedding that preserves pairwise distances.

Isomap

- 中文：先估计流形上的测地距离，再用 MDS 降维。
- English: Combining graph geodesic distances with MDS.

t-SNE

- 中文：让高维中相似的点在低维中仍靠近，常用于可视化。
- English: A visualization method preserving neighborhood probabilities using KL divergence.

Lecture 8: 感知机与 SVM

Perceptron 感知机

- 中文：线性加权求和后经过激活函数得到输出。
- English: A model computing a weighted sum followed by an activation.

Linear Classifier 线性分类器

- 中文：用直线、平面或超平面分开类别。
- English: A classifier using a hyperplane decision boundary.

Support Vector Machine, SVM 支持向量机

- 中文：寻找最大间隔分类超平面。
- English: A classifier that finds the maximum-margin separating hyperplane.

Margin 间隔

- 中文：分类边界到最近训练样本的距离。
- English: Distance from the decision boundary to the nearest training points.

Support Vector 支持向量

- 中文：离分类边界最近、真正决定边界的样本。
- English: Training points that define the maximum-margin boundary.

Hard Margin 硬间隔

- 中文：要求所有训练样本完全正确分类。
- English: SVM formulation requiring all training samples to be correctly classified.

Soft Margin 软间隔

- 中文：允许少量错误或越界，用 slack variables 处理噪声。
- English: SVM allowing margin violations using slack variables.

Kernel Trick 核技巧

- 中文：不用显式进入高维空间，只用核函数计算高维内积。
- English: Computing inner products in feature space via kernel functions without explicit mapping.

Lecture 9: 神经网络与 CNN

Logistic Regression 逻辑回归

- 中文：用 sigmoid 或 softmax 把线性输出变成概率。
- English: A linear model with probabilistic output via sigmoid or softmax.

Neural Network 神经网络

- 中文：多层线性变换和非线性激活组合起来学习复杂函数。
- English: A model composed of layers of linear transformations and nonlinear activations.

Activation Function 激活函数

- 中文：给网络加入非线性，否则多层线性叠加仍然只是线性模型。
- English: A nonlinear function enabling neural networks to model nonlinear relationships.

ReLU

- 中文：小于 0 输出 0，大于 0 原样输出。
- English: Rectified Linear Unit, $\text{ReLU}(x) = \max(0, x)$.

Softmax

- 中文：把多个类别分数变成概率分布。
- English: Converts class scores into a probability distribution.

Cross Entropy 交叉熵

- 中文：分类常用损失，真实类别概率越大损失越小。
- English: A classification loss penalizing low probability assigned to the correct class.

Backpropagation 反向传播

- 中文：用链式法则从输出层往前计算每个参数的梯度。
- English: Computing gradients through a computation graph using the chain rule.

Convolutional Neural Network, CNN 卷积神经网络

- 中文：用卷积核提取局部特征，适合图像。
- English: A neural network using convolutional filters to extract local spatial features.

Pooling 池化

- 中文：把局部区域压缩成一个值，降低尺寸并增强鲁棒性。
- English: Downsampling local regions, often using max or average pooling.

AlexNet

- 中文：2012 年推动深度学习视觉复兴的 CNN，使用 ReLU、dropout、overlap pooling 等。
- English: A landmark CNN architecture using ReLU, dropout, and multiple convolutional layers.

Lecture 10: 传统目标检测

Sliding Window 滑动窗口

- 中文：在不同位置和尺度枚举窗口，判断每个窗口是否有目标。
- English: Scanning an image over positions and scales with a classifier.

Region Proposal 区域候选

- 中文：先生成可能包含目标的候选区域，再分类。
- English: Candidate image regions likely to contain objects.

Intersection over Union, IoU 交并比

- 中文：预测框和真实框交集面积除以并集面积。
- English: The area of overlap divided by the area of union between two boxes.

Precision 查准率

- 中文：预测为正的里面有多少是真的。
- English: Fraction of predicted positives that are true positives.

Recall 查全率

- 中文：所有真实目标中有多少被找到了。
- English: Fraction of ground-truth positives detected.

Average Precision, AP 平均精度

- 中文：单个类别 precision-recall 曲线下的面积。
- English: Area under the precision-recall curve for one class.

mean Average Precision, mAP 平均 AP

- 中文：多个类别 AP 的平均值。
- English: Mean of AP over classes or IoU thresholds.

Viola-Jones Face Detector

- 中文：经典实时人脸检测方法，使用矩形特征、积分图、AdaBoost、级联分类器。
- English: A classical real-time face detector using Haar-like features, integral images, AdaBoost, and cascade classifiers.

Haar-like Rectangle Feature 矩形特征

- 中文：白色区域像素和减黑色区域像素和。
- English: Difference between sums of pixels in white and black rectangles.

AdaBoost

- 中文：把多个弱分类器加权组合成强分类器，并逐轮关注错分样本。
- English: Combining weak learners into a strong classifier by reweighting examples.

Attentional Cascade 级联分类器

- 中文：前面简单分类器快速拒绝大量负样本，后面复杂分类器精判。
- English: A cascade of classifiers that quickly rejects easy negatives and spends computation on harder cases.

Deformable Part Model, DPM 可变形部件模型

- 中文：用 root filter 表示整体，用 part filters 表示部件，并加入形变代价。
- English: An object model with a root filter, part filters, and deformation costs.

Lecture 11: 深度学习目标检测

Two-stage Detector 两阶段检测器

- 中文：先生成候选框，再对候选框分类和回归。
- English: Detector that first proposes regions and then classifies/refines them.
- 代表：R-CNN、Fast R-CNN、Faster R-CNN。

One-stage Detector 单阶段检测器

- 中文：直接在密集位置上预测类别和框。
- English: Detector that directly predicts boxes and classes without a separate proposal stage.
- 代表：YOLO。

R-CNN

- 中文：先用 selective search 产生候选区域，再把每个区域送进 CNN 提特征，最后 SVM 分类。
- English: Region-based CNN detector using region proposals, CNN features, and class-specific SVMs.

Fast R-CNN

- 中文：整图只过一次 CNN，再用 RoI Pooling 从 feature map 中提候选区域特征。
- English: Runs CNN once per image and extracts region features by RoI Pooling.

Faster R-CNN

- 中文：用 Region Proposal Network 直接生成候选框。
- English: Uses a Region Proposal Network to generate object proposals.

Region Proposal Network, RPN

- 中文：在特征图每个位置用 anchors 预测 objectness 和 bbox offset。
- English: Network predicting objectness scores and box refinements for anchors.

Anchor Box 锚框

- 中文：预设不同尺度和宽高比的参考框。
- English: Predefined reference boxes of different scales and aspect ratios.

YOLO

- 中文：把图像分成网格，每个网格直接预测边界框、置信度和类别。
- English: A real-time one-stage detector predicting boxes and classes from grid cells.

Lecture 12: 语义分割

Semantic Segmentation 语义分割

- 中文：对每个像素做分类。
- English: Pixel-wise semantic classification.

Fully Convolutional Network, FCN 全卷积网络

- 中文：把全连接层换成卷积层，使网络能输出空间 feature map。
- English: A network made of convolutional layers that outputs spatial maps.

Downsampling 下采样

- 中文：降低特征图分辨率，扩大感受野，但会损失细节。
- English: Reducing feature-map resolution while increasing receptive field.

Upsampling 上采样

- 中文：恢复分辨率，使输出回到像素级。
- English: Increasing feature-map resolution for dense prediction.

Transposed Convolution 转置卷积

- 中文：一种可学习上采样方法，不等于真正数学上的反卷积。
- English: Learnable upsampling implemented as the transpose of convolution matrix operations.

Skip Connection 跳跃连接

- 中文：把浅层细节和深层语义结合。
- English: Combining low-level detailed features with high-level semantic features.

Dilated Convolution 空洞卷积

- 中文：在卷积核元素之间插空，扩大感受野而不降采样。
- English: Convolution with gaps inserted between kernel elements to enlarge receptive field.

Mask R-CNN

- 中文：在 Faster R-CNN 上增加 mask 分支，用于实例分割。
- English: Faster R-CNN extended with a mask prediction branch.

RoI Align

- 中文：避免 RoI Pooling 的量化误差，用双线性插值精确采样。
- English: Region feature extraction without quantization, using bilinear interpolation.

Lecture 13: 目标跟踪

Single Object Tracking, SOT 单目标跟踪

- 中文：第一帧给目标，后续帧持续定位这个目标。
- English: Tracking one initialized target through subsequent frames.

Multiple Object Tracking, MOT 多目标跟踪

- 中文：同时检测并关联多个目标的身份。
- English: Detecting and associating multiple object identities over time.

State 状态

- 中文：目标的位置、尺度、速度、外观等信息。
- English: Variables describing target position, size, velocity, and appearance.

Kalman Filter 卡尔曼滤波

- 中文：用运动模型预测下一帧位置，再用观测修正。
- English: A recursive estimator combining motion prediction and measurement update.

Particle Filter 粒子滤波

- 中文：用很多随机样本表示目标状态分布。
- English: Representing a state distribution with weighted random particles.

Mean-Shift 均值漂移

- 中文：根据特征分布迭代移动窗口到最相似区域。
- English: Iteratively shifting a window toward the mode of a feature distribution.

Siamese Tracker 孪生网络跟踪器

- 中文：一个分支看模板，一个分支看搜索区域，用相似度图定位目标。
- English: A tracker comparing an exemplar and search region with shared-weight networks.

SiamFC

- 中文：用全卷积孪生网络输出相似度响应图。
- English: Fully convolutional Siamese tracker using cross-correlation for response maps.

SiamRPN

- 中文：把 Siamese 相似度与 RPN 框回归结合。
- English: Siamese tracker with region proposal prediction.

Deep SORT

- 中文：检测 + Kalman 运动预测 + 外观特征关联，用于多目标跟踪。
- English: MOT method combining detection, Kalman filtering, and deep appearance association.

Lecture 15: 视觉语言

Vision-Language Learning 视觉语言学习

- 中文：让模型同时理解图像/视频和文字，并建立二者关系。
- English: Learning models that process and relate visual and textual information.

Encoder-Decoder 编码器-解码器

- 中文：编码器把图像/句子变成特征，解码器生成目标序列。
- English: An architecture where an encoder produces representations and a decoder generates outputs.

Recurrent Neural Network, RNN 循环神经网络

- 中文：用隐藏状态记住前面序列信息。
- English: A sequence model with hidden states passed through time.

Long Short-Term Memory, LSTM 长短期记忆网络

- 中文：用门控机制缓解长序列遗忘问题。
- English: An RNN variant with gates to preserve long-term information.

Transformer

- 中文：基于 self-attention 的序列模型，可以并行建模长距离关系。
- English: A sequence model based on self-attention for modeling long-range dependencies.

Self-Attention 自注意力

- 中文：序列中每个位置都根据相关性从其他位置取信息。
- English: Each token attends to other tokens according to learned similarity.

Vision Transformer, ViT

- 中文：把图像切成 patch，当成词一样输入 Transformer。
- English: Treating image patches as tokens for Transformer-based image recognition.

Cross-modal Retrieval 跨模态检索

- 中文：用文字找图像，或用图像找文字。
- English: Retrieving items in one modality using a query from another modality.

三、公式与计算方法详解

1. 齐次坐标与几何变换

2D 点与直线

- 点： $x = [u, v, 1]^T$ 。
- 直线： $l = [a, b, c]^T$ ，点在线上满足 $l^T x = au + bv + c = 0$ 。
- 两点确定直线： $l = x_1 \times x_2$ 。
- 两线交点： $x = l_1 \times l_2$ 。

2D 变换

- 平移： $[[1, 0, t_x], [0, 1, t_y], [0, 0, 1]]$
- 缩放： $[[s_x, 0, 0], [0, s_y, 0], [0, 0, 1]]$
- 旋转： $[[\cos\theta, -\sin\theta, 0], [\sin\theta, \cos\theta, 0], [0, 0, 1]]$
- 仿射变换： $x' = A x + t$
- 单应性： $\lambda x' = H x$ ， H 有 8 个自由度，至少需要 4 对点。

2. 针孔相机与投影

归一化针孔投影

3D 点 $P = (X, Y, Z)$ 投影到归一化平面：

$$\begin{aligned} x &= X / Z \\ y &= Y / Z \end{aligned}$$

加入焦距和主点：

$$\begin{aligned} u &= f_x X / Z + c_x \\ v &= f_y Y / Z + c_y \end{aligned}$$

如果 $f_x = f_y = f$ ，则：

$$\begin{aligned}u &= fX/Z + c_x \\v &= fY/Z + c_y\end{aligned}$$

相机矩阵

$$\lambda \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}^T = K \begin{bmatrix} R & | & t \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}^T$$

其中：

$$K = \begin{bmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

- K ：intrinsic matrix 内参。
- R, t ：extrinsic parameters 外参。
- λ ：齐次尺度，通常等于相机坐标系中的深度。

投影计算步骤

1. 世界点 X_w 先变到相机坐标： $X_c = R X_w + t$ 。
2. 归一化： $x = X_c/Z_c, y = Y_c/Z_c$ 。
3. 像素坐标： $u = f_x x + c_x, v = f_y y + c_y$ 。

视场角 Field of View

如果传感器宽度为 w ，焦距为 f ：

$$FOV = 2 \arctan(w / (2f))$$

焦距越大，视场越窄，画面越“放大”。

消失点 Vanishing Point

平行线方向为 d ，其无穷远点投影：

$$v \propto K R d$$

如果方向与图像平面平行，可能产生有限消失点；如果方向没有朝深度收敛，消失点可能在无穷远。

3. 采样与量化

Nyquist-Shannon Sampling Theorem

若信号最高频率为 $f_{\max}$ ，采样频率需要：

$$f_s \geq 2 f_{\max}$$

否则会产生 aliasing 混叠。

量化

若使用 b bit 表示灰度，则灰度级数：

$$L = 2^b$$

若灰度范围 $[I_{\min}, I_{\max}]$ ，量化步长：

$$\Delta = (I_{\max} - I_{\min}) / (L - 1)$$

4. 直方图均衡化

设灰度级 r_k 的像素数为 n_k ，总像素数为 N ：

$$\begin{aligned} p(r_k) &= n_k / N \\ \text{CDF}(r_k) &= \sum_{j=0}^k p(r_j) \\ s_k &= \text{round}((L - 1) \text{CDF}(r_k)) \end{aligned}$$

做题步骤：

1. 统计每个灰度级出现次数 n_k 。
2. 计算概率 $p(r_k)$ 。
3. 计算累积分布 CDF 。
4. 用 $s_k = \text{round}((L-1)\text{CDF})$ 得到新灰度。
5. 把原图每个灰度替换成对应的新灰度。

5. 相关与卷积

给图像 I 和核 K 。

Correlation 相关

$$G[i, j] = \sum_u \sum_v K[u, v] I[i+u, j+v]$$

核不翻转。

Convolution 卷积

$$G[i,j] = \sum_u \sum_v K[u,v] I[i-u, j-v]$$

等价于先把 K 旋转 180° 再做 correlation。

卷积计算步骤

1. 判断题目要求 correlation 还是 convolution。
2. 如果是 convolution，先把核上下、左右翻转。
3. 根据 padding 补边。
4. 核中心对准当前位置。
5. 对应元素相乘再求和。
6. 按 stride 移动。

输出尺寸

输入尺寸 N ，核大小 F ，padding P ，stride S ：

$$O = \text{floor}((N - F + 2P) / S) + 1$$

二维情况：

$$\begin{aligned} O_h &= \text{floor}((H - F_h + 2P_h) / S_h) + 1 \\ O_w &= \text{floor}((W - F_w + 2P_w) / S_w) + 1 \end{aligned}$$

6. CNN 参数量

卷积核大小 $K_h \times K_w$ ，输入通道 C_{in} ，输出通道 C_{out} ：

$$\text{parameters} = (K_h K_w C_{in} + 1) C_{out}$$

$+1$ 是每个输出通道一个 bias。如果没有 bias，就去掉 $+1$ 。

例： 3×3 卷积，输入 64 通道，输出 128 通道：

$$\text{parameters} = (3 \times 3 \times 64 + 1) \times 128 = 73856$$

7. 常见滤波器

均值滤波 Box Filter

3×3 均值滤波：

```
1/9 [[1,1,1],
     [1,1,1],
     [1,1,1]]
```

作用：平滑，但容易模糊边缘。

Gaussian Filter

二维高斯：

$$G(x,y) = 1/(2\pi\sigma^2) \exp(-(x^2+y^2)/(2\sigma^2))$$

σ 越大，平滑越强。

Sobel 梯度

常见 Sobel 核：

```
G_x = [[-1,0,1],
        [-2,0,2],
        [-1,0,1]]

G_y = [[-1,-2,-1],
        [ 0, 0, 0],
        [ 1, 2, 1]]
```

梯度幅值和方向：

$$|\nabla I| = \sqrt{I_x^2 + I_y^2}$$

$$\theta = \text{atan2}(I_y, I_x)$$

Laplacian 拉普拉斯

$$\nabla^2 I = I_{xx} + I_{yy}$$

常见离散核：

```
[[0, 1, 0],
 [1, -4, 1],
```

```
[0, 1, 0]]
```

或：

```
[[1, 1, 1],
 [1, -8, 1],
 [1, 1, 1]]
```

Laplacian 对噪声敏感，所以常先 Gaussian 平滑。

8. 双边滤波

$$J(p) = 1/W_p \sum_{q \in N(p)} G_s(||p-q||) G_r(|I_p - I_q|) I_q$$

其中：

$$\begin{aligned} G_s &= \exp(-||p-q||^2 / (2\sigma_s^2)) \\ G_r &= \exp(-|I_p - I_q|^2 / (2\sigma_r^2)) \\ W_p &= \sum_{q \in N(p)} G_s G_r \end{aligned}$$

- σ_s 控制空间距离影响。
- σ_r 控制像素值差异影响。
- 边缘两侧像素值差异大， G_r 小，因此不会强行平均，能保边。

9. 积分图

定义：

$$S(x,y) = \sum_{i \leq x, j \leq y} I(i,j)$$

递推计算：

$$S(x,y) = I(x,y) + S(x-1,y) + S(x,y-1) - S(x-1,y-1)$$

矩形区域左上为 A，右上为 B，左下为 C，右下为 D，区域和：

$$\text{sum} = S(D) - S(B) - S(C) + S(A)$$

注意具体加减取决于坐标是否 inclusive。考试时按题目给的角点定义来。

10. 形态学

设二值图像集合为 A ，结构元素为 B 。

Dilation 膨胀

$$A \oplus B = \{z \mid (B)_z \text{ intersects } A\}$$

效果：目标变粗、连接小裂缝。

Erosion 腐蚀

$$A \ominus B = \{z \mid (B)_z \subseteq A\}$$

效果：目标变细、去掉小噪声。

Opening 开运算

$$A \circ B = (A \ominus B) \oplus B$$

先腐蚀后膨胀，去小白点。

Closing 闭运算

$$A \bullet B = (A \oplus B) \ominus B$$

先膨胀后腐蚀，填小黑洞。

11. 傅里叶变换与频域滤波

二维离散傅里叶变换：

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \exp(-j2\pi(ux/M + vy/N))$$

逆变换：

$$f(x, y) = 1/(MN) \sum_u \sum_v F(u, v) \exp(j2\pi(ux/M + vy/N))$$

卷积定理：

$$f * h \Leftrightarrow F \cdot H$$

$$f \cdot h \Leftrightarrow F * H$$

频域理解：

- 低频：大块平滑区域、光照变化。
- 高频：边缘、纹理、噪声。
- Gaussian smoothing：低通滤波。
- Laplacian / high-pass：强调高频。

12. 金字塔

Gaussian Pyramid

$$G_0 = I$$

$$G_{l+1} = \text{downsample}(G_l * g)$$

先低通滤波 g ，再下采样。

Laplacian Pyramid

$$L_l = G_l - \text{expand}(G_{l+1})$$

重建：

$$G_l = L_l + \text{expand}(G_{l+1})$$

Pyramid Blending

1. 对图像 A、B 建 Laplacian pyramids。
2. 对 mask 建 Gaussian pyramid。
3. 每层融合： $L_l = M_l L_l^A + (1-M_l)L_l^B$
4. 从顶层逐层重建。

13. Harris 角点

窗口平移 (u, v) 后变化：

$$E(u, v) = \sum_{\{x, y\}} w(x, y) [I(x+u, y+v) - I(x, y)]^2$$

一阶泰勒近似：

$$I(x+u, y+v) \approx I(x, y) + I_x u + I_y v$$

所以：

$$E(u, v) \approx [u \ v] M [u \ v]^T$$

二阶矩阵：

$$M = \sum w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

Harris response：

$$R = \det(M) - k \text{trace}(M)^2$$

其中：

$$\begin{aligned} \det(M) &= \lambda_1 \lambda_2 \\ \text{trace}(M) &= \lambda_1 + \lambda_2 \end{aligned}$$

判断：

- λ_1 小、 λ_2 小：平坦区域。
- 一个大一个小：边缘。
- 两个都大：角点。

步骤：

1. 计算 I_x, I_y 。
2. 计算 $I_x^2, I_y^2, I_x I_y$ 。
3. 用 Gaussian window 做局部加权求和得到 M 。
4. 计算 R 。
5. 阈值筛选并做 non-maximum suppression。

14. LoG、DoG 与尺度空间

尺度空间：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$$

LoG:

$$\text{LoG} = \nabla^2 (G_\sigma * I)$$

尺度归一化:

$$\sigma^2 \nabla^2 G$$

DoG:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

DoG 近似 LoG:

$$D(x, y, \sigma) \approx (k-1) \sigma^2 \nabla^2 G$$

SIFT 在位置和尺度空间寻找局部极值。

15. SIFT 描述子与匹配

方向与幅值

$$\begin{aligned} m(x, y) &= \sqrt{((I(x+1, y) - I(x-1, y))^2 + (I(x, y+1) - I(x, y-1))^2)} \\ \theta(x, y) &= \text{atan2}(I(x, y+1) - I(x, y-1), I(x+1, y) - I(x-1, y)) \end{aligned}$$

描述子

- 关键点邻域旋转到主方向。
- 分成 4×4 cells。
- 每个 cell 统计 8 个方向 bin。
- 总维度: $4 \times 4 \times 8 = 128$ 。
- 归一化, 截断大值, 再归一化, 减少光照影响。

NNDR 匹配

设最近邻距离 d_1 , 次近邻距离 d_2 :

$$\text{ratio} = d_1 / d_2$$

若 $\text{ratio} < \text{threshold}$, 例如 0.8 , 接受匹配; 否则认为不可靠。

16. 最小二乘

OLS 拟合直线

直线：

$$y_i = m x_i + b$$

矩阵形式：

$$\begin{aligned} X\beta &= y \\ X &= \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \\ \beta &= [m, b]^T \end{aligned}$$

最小化：

$$\min ||X\beta - y||^2$$

解：

$$\beta = (X^T X)^{-1} X^T y$$

注意：OLS 最小化的是竖直方向误差，遇到接近竖直的线会不稳定。

TLS 拟合直线

直线：

$$ax + by = d, \quad a^2 + b^2 = 1$$

点到线距离：

$$|a x_i + b y_i - d|$$

TLS 最小化正交距离：

$$\min \sum (a x_i + b y_i - d)^2$$

常用步骤：

1. 计算点集中心 $c = \text{mean}(x_i, y_i)$ 。
2. 中心化点 $p_i - c$ 。
3. 计算协方差矩阵。
4. 最小特征值对应的特征向量是直线法向量 $[a, b]$ 。
5. $d = a c_x + b c_y$ 。

17. RANSAC

目标：大量 outliers 中找到正确模型。

迭代次数公式：

$$N = \log(1-p) / \log(1-w^s)$$

其中：

- p ：希望至少抽到一次全内点样本的概率。
- w ：内点比例。
- s ：拟合模型所需最小样本数。

例： $p=0.99, w=0.5, s=2$ ：

$$\begin{aligned} N &= \log(0.01) / \log(1-0.25) \\ &= -4.6052 / \log(0.75) \\ &\approx 16.0 \end{aligned}$$

所以至少约 16 次。

RANSAC 步骤：

1. 随机抽 s 个点。
2. 拟合一个模型。
3. 用阈值判断所有点是否为 inliers。
4. 记录 consensus set 大小。
5. 重复 N 次。
6. 用最大内点集合重新拟合最终模型。

18. Hough 变换

直线的极坐标表示

$$\rho = x \cos\theta + y \sin\theta$$

做题步骤：

1. 初始化参数空间 accumulator。
2. 对每个边缘点 (x, y) 。
3. 枚举 θ 。
4. 计算 ρ 。
5. 给 (ρ, θ) 单元投票。
6. 峰值位置对应检测到的直线。

圆 Hough

圆方程：

$$(x-a)^2 + (y-b)^2 = r^2$$

- 若 r 已知，参数空间是 (a, b) 。
- 若 r 未知，参数空间是 (a, b, r) 。

19. PCA

数据 $x_i \in \mathbb{R}^D$ 。

步骤：

1. 均值： $\mu = 1/n \sum x_i$
2. 中心化： $z_i = x_i - \mu$
3. 协方差： $S = 1/n \sum z_i z_i^T$
4. 特征分解： $S v_i = \lambda_i v_i$
5. 选最大 k 个特征值对应特征向量组成 W 。
6. 投影： $y = W^T (x - \mu)$
7. 重建： $\hat{x} = \mu + W y$

解释方差比：

$$\text{explained variance ratio} = (\sum_{i=1}^k \lambda_i) / (\sum_{i=1}^D \lambda_i)$$

20. Kernel PCA 与流形学习

Kernel PCA

核矩阵：

$$K_{ij} = k(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

中心化核矩阵：

$$K_c = K - \mathbf{1}_n K - K \mathbf{1}_n + \mathbf{1}_n K \mathbf{1}_n$$

其中 $\mathbf{1}_n$ 是所有元素为 $1/n$ 的矩阵。

LLE

先求局部重构权重：

$$\begin{aligned} \min \sum_i ||x_i - \sum_{j \in N(i)} w_{ij} x_j||^2 \\ \text{s.t. } \sum_j w_{ij} = 1 \end{aligned}$$

再求低维嵌入：

$$\min \sum_i ||y_i - \sum_j w_{ij} y_j||^2$$

Laplacian Eigenmaps

图权重 w_{ij} ，度矩阵 $D_{ii} = \sum_j w_{ij}$ ，图拉普拉斯：

$$L = D - W$$

求广义特征问题：

$$L y = \lambda D y$$

MDS

距离矩阵平方 D^2 ，中心化矩阵：

$$\begin{aligned} J &= I - (1/n)\mathbf{1}\mathbf{1}^T \\ B &= -1/2 J D^2 J \end{aligned}$$

对 B 做特征分解得到低维坐标。

t-SNE

高维相似度 p_{ij} ，低维相似度 q_{ij} ，最小化：

$$KL(P \parallel Q) = \sum_i \sum_j p_{ij} \log(p_{ij} / q_{ij})$$

21. SVM

线性分类器：

$$f(x) = \text{sign}(w^T x + b)$$

间隔：

$$\text{margin width} = 2 / ||w||$$

Hard-margin SVM

$$\begin{aligned} \min & \ 1/2 \ ||w||^2 \\ \text{s.t.} & \ y_i(w^T x_i + b) \geq 1 \end{aligned}$$

Soft-margin SVM

$$\begin{aligned} \min & \ 1/2 \ ||w||^2 + C \sum \xi_i \\ \text{s.t.} & \ y_i(w^T x_i + b) \geq 1 - \xi_i \\ & \ \xi_i \geq 0 \end{aligned}$$

Dual form

$$\begin{aligned} \max & \ \sum_i \alpha_i - 1/2 \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{s.t.} & \ 0 \leq \alpha_i \leq C \\ & \ \sum_i \alpha_i y_i = 0 \end{aligned}$$

预测：

$$f(x) = \text{sign}(\sum_i \alpha_i y_i K(x_i, x) + b)$$

常见核：

Linear: $K(x, z) = x^T z$
Polynomial: $K(x, z) = (1 + x^T z)^p$
RBF: $K(x, z) = \exp(-||x-z||^2 / (2\sigma^2))$

22. 神经网络、Softmax 与反向传播

一层神经网络

$$z = W x + b$$
$$a = \phi(z)$$

Sigmoid

$$\sigma(z) = 1 / (1 + \exp(-z))$$

ReLU

$$\text{ReLU}(z) = \max(0, z)$$

Softmax

$$p_k = \exp(z_k) / \sum_j \exp(z_j)$$

Cross Entropy

one-hot 标签 y :

$$L = -\sum_k y_k \log p_k$$

若真实类别是 c :

$$L = -\log p_c$$

SGD 更新

$$\theta \leftarrow \theta - \eta \partial L / \partial \theta$$

链式法则

如果：

$$L = f(g(h(x)))$$

则：

$$dL/dx = dL/df \cdot df/dg \cdot dg/dh \cdot dh/dx$$

反向传播就是把这个过程系统地应用在计算图上。

23. 目标检测评价

IoU

$$\text{IoU} = \text{area}(B_{\text{pred}} \cap B_{\text{gt}}) / \text{area}(B_{\text{pred}} \cup B_{\text{gt}})$$

若 $\text{IoU} \geq \text{threshold}$ ，通常认为定位正确。

Precision / Recall

$$\begin{aligned} \text{Precision} &= TP / (TP + FP) \\ \text{Recall} &= TP / (TP + FN) \end{aligned}$$

AP

AP 是 precision-recall 曲线下的面积。

常见 all-point interpolation：

$$AP = \sum_n (R_n - R_{n-1}) P_{\text{interp}}(R_n)$$

其中：

$$P_{\text{interp}}(R_n) = \max_{\{R' \geq R_n\}} P(R')$$

mAP

$$\text{mAP} = (1/C) \sum_{c=1}^C \text{AP}_c$$

NMS 非极大值抑制

步骤：

1. 按 confidence 从高到低排序。
2. 取最高分框保留。
3. 删除与它 IoU 大于阈值的其他框。
4. 重复直到没有框。

24. Viola-Jones 与 AdaBoost

矩形特征

$$\text{feature} = \sum \text{white pixels} - \sum \text{black pixels}$$

用 integral image 可以快速计算矩形和。

AdaBoost 权重更新思想

1. 初始样本权重相同。
2. 每轮训练一个弱分类器。
3. 错分样本权重增大。
4. 正确样本权重减小。
5. 最终分类器是弱分类器加权和。

Cascade 总检测率与误检率

若每层 detection rate 为 d_i ，false positive rate 为 f_i ：

$$\begin{aligned} \text{overall detection rate} &= \prod_i d_i \\ \text{overall false positive rate} &= \prod_i f_i \end{aligned}$$

25. DPM 得分

DPM 由 root filter 和多个 part filters 构成。

简化得分：

$$\text{score} = \text{root_score} + \sum_i \text{part_score}_i - \sum_i \text{deformation_cost}_i$$

典型形变代价：

$$\text{deformation_cost} = a \, dx^2 + b \, dx + c \, dy^2 + d \, dy$$

26. R-CNN、Fast R-CNN、Faster R-CNN

R-CNN

1. Selective Search 产生约 2000 个 proposals。
2. 每个 proposal resize 后送入 CNN。
3. CNN 特征给 SVM 分类。
4. bbox regressor 修正框。

缺点：每个 proposal 单独跑 CNN，慢。

Fast R-CNN

1. 整张图跑一次 CNN。
2. proposals 投影到 feature map。
3. RoI Pooling 得到固定尺寸特征。
4. 分类 + bbox regression。

Faster R-CNN

1. Backbone 提取 feature map。
2. RPN 在 anchors 上预测 objectness 和 bbox offsets。
3. proposals 进入 RoI head。
4. RoI head 做最终分类和框回归。

RPN 常见四类 loss：

- RPN classification loss。
- RPN bbox regression loss。
- Final classification loss。
- Final bbox regression loss。

边界框回归参数

anchor 为 (x_a, y_a, w_a, h_a) ，目标框为 (x, y, w, h) ：

$$\begin{aligned} t_x &= (x - x_a) / w_a \\ t_y &= (y - y_a) / h_a \\ t_w &= \log(w / w_a) \\ t_h &= \log(h / h_a) \end{aligned}$$

27. YOLO

YOLOv1 思路：

- 图像分成 $S \times S$ 网格。

- 每个 grid cell 预测 B 个 boxes。
- 每个 box 预测坐标、confidence。
- 每个 cell 预测 class probabilities。

Confidence:

$$\text{confidence} = P(\text{object}) \times \text{IoU}(\text{pred}, \text{gt})$$

类别得分:

$$\begin{aligned} \text{class-specific score} &= P(\text{class} \mid \text{object}) \times \text{confidence} \\ &= P(\text{class}) \times \text{IoU} \end{aligned}$$

YOLO loss 简化管理:

$$\text{Loss} = \text{coordinate loss} + \text{confidence loss} + \text{classification loss}$$

坐标误差只惩罚负责某个 ground truth 的预测框；无目标框的 confidence loss 通常乘较小权重。

28. 语义分割指标与上采样

Pixel Accuracy

$$\text{pixel accuracy} = \text{correct pixels} / \text{total pixels}$$

缺点：类别不平衡时可能虚高。

IoU for segmentation

对某个类别:

$$\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN})$$

mIoU

$$\text{mIoU} = \text{average IoU over classes}$$

Dilated Convolution 有效核大小

核大小 k , dilation rate d :

$$k_{\text{eff}} = k + (k - 1)(d - 1)$$

例：3×3 核，d=2：

$$k_{\text{eff}} = 3 + 2 \times 1 = 5$$

29. Bilinear Interpolation 与 RoI Align

对非整数坐标 (x,y)，设：

$$\begin{aligned} x_0 &= \text{floor}(x), \quad x_1 = x_0 + 1 \\ y_0 &= \text{floor}(y), \quad y_1 = y_0 + 1 \end{aligned}$$

双线性插值：

$$\begin{aligned} I(x,y) &= \\ &I(x_0,y_0)(x_1-x)(y_1-y) + \\ &I(x_1,y_0)(x-x_0)(y_1-y) + \\ &I(x_0,y_1)(x_1-x)(y-y_0) + \\ &I(x_1,y_1)(x-x_0)(y-y_0) \end{aligned}$$

RoI Align 不把 RoI 边界和 bin 坐标强行取整，所以减少量化误差。

30. Kalman Filter 与 Deep SORT

Kalman Predict

$$\begin{aligned} x'_t &= F x_{t-1} + B u_t \\ P'_t &= F P_{t-1} F^T + Q \end{aligned}$$

Kalman Update

$$\begin{aligned} K_t &= P'_t H^T (H P'_t H^T + R)^{-1} \\ x_t &= x'_t + K_t (z_t - H x'_t) \\ P_t &= (I - K_t H) P'_t \end{aligned}$$

Deep SORT 常用状态：

$$[u, v, r, h, u_{\text{dot}}, v_{\text{dot}}, r_{\text{dot}}, h_{\text{dot}}]$$

- u, v : bbox center。
- r : aspect ratio。
- h : height。
- dot 表示速度。

运动关联 Mahalanobis distance:

$$d = (z - Hx)^T S^{-1} (z - Hx)$$

外观关联通常用 cosine distance。总 cost 可写成:

$$\text{cost} = \lambda d_{\text{motion}} + (1-\lambda) d_{\text{appearance}}$$

31. RNN、LSTM 与 Transformer

RNN

$$\begin{aligned} h_t &= \phi(W_{xh} x_t + W_{hh} h_{t-1} + b_h) \\ y_t &= \text{softmax}(W_{hy} h_t + b_y) \end{aligned}$$

LSTM

典型门控:

$$\begin{aligned} f_t &= \sigma(W_f [h_{t-1}, x_t] + b_f) \\ i_t &= \sigma(W_i [h_{t-1}, x_t] + b_i) \\ g_t &= \tanh(W_g [h_{t-1}, x_t] + b_g) \\ c_t &= f_t \odot c_{t-1} + i_t \odot g_t \\ o_t &= \sigma(W_o [h_{t-1}, x_t] + b_o) \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

Scaled Dot-Product Attention

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$$

含义:

- Q : 我要找什么。

- **K**: 每个位置有什么标签。
- **V**: 真正要取走的信息。
- 除以 $\sqrt{d_k}$ 防止点积过大导致 softmax 过尖。

Multi-Head Attention

多个 attention head 并行学习不同关系：

```
head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)
MHA = concat(head_1, ..., head_h) W^O
```

四、用 8 岁小孩能听懂的话讲懂

你可以把计算机视觉想成：我们在教电脑“看图做作业”。

1. **相机成像**：相机像一个小窗户。外面的东西通过小窗户照到纸上，远的东西看起来小，近的东西看起来大。
2. **像素**：一张图片像一张方格纸，每个小格子有一个颜色数字。
3. **滤波**：滤波像拿一个小印章在图片上一个格子一个格子地滑。每次看周围几个格子，算出一个新数字。
4. **卷积**：卷积就是一种特别的滑动印章。真正卷积要先把印章转 180° ，再盖到图上算乘法加法。
5. **模糊**：高斯滤波像用软橡皮轻轻擦图，让小噪声变淡。
6. **边缘**：边缘就是颜色突然变化的地方，像白纸和黑线交界。
7. **频率**：低频像大块颜色，高频像细线、边缘和噪声。
8. **金字塔**：把一张大图变成越来越小的图，像先看全局，再看细节。
9. **角点**：角点像桌角、窗角这种特别好认的点，图片移动后也容易再找到。
10. **SIFT**：给每个角点做一张“身份证”，记录周围边缘朝哪个方向。
11. **RANSAC**：如果很多点里有一些乱点，RANSAC 就像反复随机找几个人试答案，谁得到最多人支持，就相信谁。
12. **PCA**：把一堆复杂数据转个方向，只保留最重要的方向，让问题变简单。
13. **SVM**：在两类东西中间画一条尽量宽的分界线，离两边都远一点，这样不容易分错。
14. **神经网络**：像很多层小计算器，前面看简单形状，后面组合成更复杂的东西。
15. **CNN**：专门看图片的神经网络，用很多小滤波器找边、角、纹理、部件。
16. **目标检测**：不仅说图里有什么，还要用框圈出来在哪里。
17. **语义分割**：给每个像素涂类别颜色，比如路面一类、天空一类、建筑一类。
18. **跟踪**：在视频里一直盯着同一个目标，猜它下一帧会去哪，再用新画面修正。
19. **Transformer**：每个词或图像小块都问其他位置：“谁和我有关？”然后把有用信息拿过来。
20. **视觉语言**：让电脑既看图又读文字，比如看图写一句话，或根据一句话找图里的区域。

一句话总结：这门课是在学怎么把图片变成数字，怎么用数学找边、角、框和区域，最后怎么让模型理解图片和文字。

五、模拟试卷

选择题 25 题

每题只有一个最佳答案。

1. Computer Vision 最核心的目标是： A. 只压缩图像文件
B. 让机器捕获、理解和预测视觉信息
C. 只提高屏幕亮度
D. 只画 3D 动画
2. 针孔相机模型中，3D 点 (X, Y, Z) 的归一化投影坐标是： A. $(X+Z, Y+Z)$
B. $(X/Z, Y/Z)$
C. (XZ, YZ)
D. $(X-Y, Y-X)$
3. 齐次坐标的主要作用是： A. 让图像变清晰
B. 用矩阵统一表示平移、投影等变换
C. 增加图像颜色数量
D. 删除图像噪声
4. 图像中的 vanishing point 指： A. 噪声消失的位置
B. 颜色为 0 的像素
C. 3D 平行线在图像中相交的点
D. 图像中心点
5. 直方图均衡化主要使用： A. 梯度方向
B. 累积分布函数 CDF
C. 傅里叶相位
D. RANSAC 随机采样
6. 数学意义上的 convolution 与 correlation 的关键区别是： A. convolution 不需要乘法
B. convolution 需要先将核翻转 180°
C. correlation 一定改变图像尺寸
D. correlation 只能用于彩色图
7. 输入尺寸 32×32 ，卷积核 5×5 ，padding 2，stride 1，输出尺寸是： A. 28×28
B. 30×30
C. 32×32
D. 36×36
8. Gaussian filter 的主要作用是： A. 增强随机噪声
B. 平滑图像并降低高频噪声
C. 直接输出类别标签
D. 只改变图像大小
9. Fourier transform 中 magnitude 主要表示： A. 某个频率成分有多强
B. 图像的类别
C. 目标的边界框
D. 像素的 RGB 顺序
10. Laplacian pyramid 中每层主要保存： A. 低频模糊图
B. 相邻 Gaussian 层之间的细节残差
C. 类别概率
D. 相机内参

11. Harris 角点中，如果结构张量两个特征值都大，通常说明： A. 平坦区域
B. 边缘
C. 角点
D. 图像外部区域
12. SIFT 经典描述子的维度是： A. 16
B. 32
C. 64
D. 128
13. RANSAC 迭代次数公式中 w 表示： A. 图像宽度
B. 内点比例
C. 卷积核权重总和
D. 学习率
14. Hough 直线变换常用的极坐标形式是： A. $\rho = x \cos\theta + y \sin\theta$
B. $\rho = xy + \theta$
C. $x = \rho + \theta$
D. $y = \rho x^2$
15. PCA 选择主成分的依据是： A. 最小颜色值
B. 最大方差方向
C. 最大图像面积
D. 最小类别数
16. SVM 中 support vectors 是： A. 所有测试样本
B. 离分类边界最近并决定边界的训练样本
C. 图像中的角点
D. CNN 的卷积核
17. Kernel trick 的作用是： A. 显式存储所有高维特征
B. 直接用核函数计算高维内积
C. 删除所有支持向量
D. 把分类变成回归
18. Softmax 的输出满足： A. 每一类概率都小于 0
B. 所有类别概率和为 1
C. 只能有两个类别
D. 与输入分数无关
19. 3×3 卷积，输入通道 16，输出通道 32，带 bias，参数量为： A. $3 \times 3 \times 16 = 144$
B. $(3 \times 3 \times 16 + 1) \times 32 = 4640$
C. $3 \times 3 \times 32 = 288$
D. $16 \times 32 = 512$
20. IoU 的定义是： A. 两个框面积之和
B. 交集面积除以并集面积
C. 预测框面积除以图像面积
D. 真实框面积除以预测框面积

21. Viola-Jones 检测器不包含下列哪项核心思想： A. 矩形特征
B. 积分图
C. AdaBoost
D. Transformer self-attention
22. Faster R-CNN 相比 Fast R-CNN 的关键改进是： A. 用 RPN 生成候选区域
B. 完全不用 CNN
C. 只能处理灰度图
D. 删除边界框回归
23. YOLO 中 confidence 通常表示： A. $P(\text{object}) \times \text{IoU}$
B. $P(\text{background})$
C. 图像宽度
D. 卷积核大小
24. 语义分割中 mIoU 是： A. 每个类别 IoU 的平均
B. 每个像素亮度平均
C. 每张图面积平均
D. 每个卷积核参数平均
25. Transformer self-attention 的核心计算是： A. $\text{softmax}(QK^T/\text{sqrt}(d_k))V$
B. $X^T X$
C. $\rho = x \cos\theta + y \sin\theta$
D. $\text{IoU} = TP/(TP+FP)$

大题 1：卷积计算

给定灰度图像：

```
I =
[[1, 2, 0, 1],
 [3, 1, 2, 0],
 [0, 1, 3, 1],
 [2, 0, 1, 2]]
```

卷积核：

```
K =
[[ 1, 0, -1],
 [ 1, 0, -1],
 [ 1, 0, -1]]
```

要求：按**真正的数学卷积**计算，先把核旋转 180°；zero padding = 1；stride = 1。

1. 写出翻转后的核。
2. 写出输出尺寸。
3. 计算完整输出矩阵。

大题 2：目标检测评价计算

某图像中有两个 ground-truth boxes：

```
G1 = (0, 0, 100, 100)
G2 = (100, 0, 200, 100)
```

预测框按 confidence 从高到低排序：

```
P1 score=0.95, box=(120,20,180,80)
P2 score=0.90, box=(10,10,90,90)
P3 score=0.80, box=(15,15,85,85)
P4 score=0.70, box=(110,10,190,90)
```

采用 IoU threshold = 0.5。每个 ground truth 最多只能匹配一个预测框。

1. 分别判断 P1-P4 是 TP 还是 FP。
2. 写出每一步的 precision 和 recall。
3. 用 all-point interpolation 计算 AP。

六、答案与解析

选择题答案

- 1 B
- 2 B
- 3 B
- 4 C
- 5 B
- 6 B
- 7 C
- 8 B
- 9 A
- 10 B
- 11 C
- 12 D
- 13 B
- 14 A
- 15 B
- 16 B
- 17 B
- 18 B
- 19 B
- 20 B
- 21 D
- 22 A
- 23 A

24 A

25 A

选择题简析

1. CV 是让机器理解视觉信息。
2. 透视投影核心是除以深度。
3. 齐次坐标使投影和平移都能用矩阵表示。
4. 消失点来自 3D 平行线的透视相交。
5. 直方图均衡化用 CDF 做灰度映射。
6. 卷积比相关多一步核翻转。
7. $0 = (32 - 5 + 2 \times 2) / 1 + 1 = 32$ 。
8. Gaussian 是低通平滑滤波。
9. magnitude 表示频率强度, phase 与空间布局有关。
10. Laplacian pyramid 保存 band-pass residual。
11. 两个方向变化都大是角点。
12. SIFT 是 $4 \times 4 \times 8 = 128$ 。
13. RANSAC 中 w 是 inlier ratio。
14. Hough 线常用 $p = x \cos \theta + y \sin \theta$ 。
15. PCA 取最大方差方向。
16. 支持向量决定最大间隔边界。
17. 核技巧避免显式高维映射。
18. softmax 输出概率分布。
19. 参数量 $(3 \times 3 \times 16 + 1) \times 32 = 4640$ 。
20. IoU 是 intersection / union。
21. Viola-Jones 是矩形特征、积分图、AdaBoost、cascade, 不是 Transformer。
22. Faster R-CNN 用 RPN 替代外部 proposal 方法。
23. YOLO confidence 是目标存在概率与定位 IoU 的组合。
24. mIoU 是类别 IoU 平均。
25. self-attention 标准形式是 $\text{softmax}(QK^T / \sqrt{d_k})V$ 。

大题 1 答案

1. 翻转后的核

原核:

```
[[ 1, 0, -1],  
 [ 1, 0, -1],  
 [ 1, 0, -1]]
```

旋转 180° 后:

```
K_flip =  
[[-1, 0, 1],
```

```
[-1, 0, 1],  
[-1, 0, 1]]
```

2. 输出尺寸

输入 4×4 ，核 3×3 ，padding $P=1$ ，stride $S=1$ ：

$$O = \text{floor}((4 - 3 + 2 \times 1) / 1) + 1 = 4$$

所以输出为 4×4 。

3. 输出矩阵

zero padding 后，每个位置用 K_{flip} 做乘加。结果为：

```
G =  
[[ 3, -2, -2, -2],  
 [ 4,  1, -2, -5],  
 [ 2,  1,  1, -6],  
 [ 1,  2,  2, -4]]
```

举例计算左上角输出 $G[0,0]$ ：

padding 后左上 3×3 邻域：

```
[[0,0,0],  
 [0,1,2],  
 [0,3,1]]
```

乘以：

```
[[ -1, 0, 1],  
 [ -1, 0, 1],  
 [ -1, 0, 1]]
```

得到：

$$0 + 0 + 0 + 0 + 0 + 2 + 0 + 0 + 1 = 3$$

所以 $G[0,0]=3$ 。

大题 2 答案

Ground truth 面积:

```
area(G1)=100×100=10000  
area(G2)=100×100=10000
```

P1

$P1=(120,20,180,80)$ ，面积:

```
60×60=3600
```

与 $G2$ 的交集也是 $60×60=3600$ ，并集:

```
10000 + 3600 - 3600 = 10000
```

```
IoU(P1,G2)=3600/10000=0.36 < 0.5
```

所以 $P1 = FP$ 。

P2

$P2=(10,10,90,90)$ ，面积:

```
80×80=6400
```

与 $G1$ 交集 6400 ，并集:

```
10000 + 6400 - 6400 = 10000
```

```
IoU(P2,G1)=6400/10000=0.64 ≥ 0.5
```

$G1$ 尚未匹配，所以 $P2 = TP$ 。

P3

$P3=(15,15,85,85)$ 与 $G1$ 的 IoU 为:

```
area(P3)=70×70=4900
IoU=4900/10000=0.49 < 0.5
```

并且 G1 已被 P2 匹配，所以无论按 IoU 还是重复检测，P3 = FP。

P4

P4=(110,10,190,90)，面积：

```
80×80=6400
```

与 G2 交集 6400，并集：

```
10000 + 6400 - 6400 = 10000
```

```
IoU(P4,G2)=6400/10000=0.64 ≥ 0.5
```

G2 尚未匹配，所以 P4 = TP。

逐步 Precision / Recall

总 ground truth 数为 2。

```
After P1: TP=0, FP=1, Precision=0/1=0, Recall=0/2=0
After P2: TP=1, FP=1, Precision=1/2=0.5, Recall=1/2=0.5
After P3: TP=1, FP=2, Precision=1/3≈0.333, Recall=1/2=0.5
After P4: TP=2, FP=2, Precision=2/4=0.5, Recall=2/2=1.0
```

All-point interpolation AP

先做插值 precision：

```
P_interp(r) = max precision at recall >= r
```

有效 recall 增加发生在：

```
R: 0 -> 0.5 -> 1.0
```

在 R=0.5 之后，最大 precision 是 0.5；在 R=1.0 时，precision 是 0.5。

所以：

$$\begin{aligned} AP &= (0.5 - 0) \times 0.5 + (1.0 - 0.5) \times 0.5 \\ &= 0.25 + 0.25 \\ &= 0.5 \end{aligned}$$

最终：

$$AP = 0.5$$

七、最后复习建议

1. 先背概念：classification、detection、segmentation、tracking 的输入输出必须清楚。
2. 再练计算：卷积、输出尺寸、IoU/AP、Harris、RANSAC、PCA、SVM 是最像考试题的部分。
3. 最后串模型：Viola-Jones 到 DPM 到 R-CNN/Faster R-CNN/YOLO，再到 FCN/Mask R-CNN/Deep SORT/Transformer。
4. 遇到公式题先写变量含义，再代数值，不要直接跳答案。
5. 卷积题一定先问自己：题目要 convolution 还是 correlation，padding 和 stride 是多少。